


Detecção de Fraude com Machine Learning

Uma Comparação em Dados Altamente Desbalanceados


O Desafio do Desbalanceamento

O problema central deste dataset financeiro europeu é a assimetria extrema entre as classes.

- ▶ Transações Legítimas: **284.315 (99,827%)**
- ▶ Fraudes Confirmadas: **492 (0,173%)**
- ▶ **Risco:** Modelos ingênuos podem atingir 99,8% de acurácia apenas classificando tudo como legítimo, falhando completamente em detectar as fraudes.



Características e Distribuição



As variáveis do dataset (V1 a V28) passaram por uma transformação PCA para garantir o anonimato dos titulares.

- ▶ Apenas as features **Time** (segundos) e **Amount** (Euros) mantiveram sua escala original.
- ▶ A distribuição dos valores transacionados é caracteristicamente assimétrica (long-tail), exigindo normalização ou transformação em árvore para modelagem eficiente.

Rigor Metodológico

Prevenção de Data Leakage


Foi utilizado o **Pipeline** do Scikit-Learn para o **StandardScaler** (aplicado a Amount e Time). Isso garante que o redimensionamento ocorra exclusivamente com os dados de treino dentro de cada fold da validação cruzada, prevenindo vazamentos de dados para o conjunto de validação.

Validação Estratificada

Aplicamos uma divisão inicial rígida de **80/20**. O ajuste de hiperparâmetros utilizou **GridSearchCV** acoplado a um **StratifiedKFold** de 5 splits. Isso assegura que a proporção minúscula de fraudes (0,17%) seja idêntica em todos os recortes de treinamento e teste.

Avaliação: Modelos e Métricas


Regressão Linear



Simplicidade & Interpretabilidade

Utiliza `class_weight='balanced'` para compensar o desbalanceamento, garantindo que a classe minoritária (fraude) não seja ignorada pelo modelo.


Random Forest



Robustez de Conjunto

Configurada com `max_depth=20` e pesos balanceados. Captura relações não-lineares complexas através de múltiplas árvores de decisão.


XGBoost (Top Performer)




Gradient Boosting Otimizado

Ajuste agressivo com `scale_pos_weight` ≈ 578 , penalizando severamente erros em fraudes para maximizar o recall.

Avaliação: ROC vs Precision-Recall




AUC-PR (Métrica Primária): Extremamente sensível a falsos positivos em classes desbalanceadas. XGBoost atinge **0.865**.




AUC-ROC: Inflada pelos milhares de verdadeiros negativos. Faz os modelos lineares parecerem melhores do que são na prática.

Importância de **Features**

- ▶ Apesar da opacidade do PCA, os modelos de árvore revelam um padrão consistente na extração de sinais.
- ▶ Componentes como **V14**, **V17** e **V12** emergem repetidamente no topo de importância tanto no Random Forest quanto no XGBoost.
- ▶ Isso corrobora a análise visual de correlação, indicando que essas dimensões latentes capturaram a variância central que distingue o comportamento fraudulento.



Matrizes de Confusão e Trade-offs



A regressão logística gera um volume impraticável de Falsos Positivos.

- ▶ **Random Forest:** Foca em Precisão (**89,7%**). Minimizou alertas falsos, errando muito menos casos individuais.
- ▶ **XGBoost:** Priorizou o Recall (**83,6%**), detectando sutilmente mais fraudes ao custo de alguns falsos positivos.
- ▶ O Teste de McNemar (**p = 0,027**) confirmou diferença estatisticamente significativa entre os dois Ensembles.

Métricas no Conjunto de Teste

Classificador	AUC-PR	F1-Score	Precision	Recall
Regressão Logística	0.7205	0.1139	0.0607	0.9184
Random Forest	0.8567	0.8495	0.8977	0.8061
XGBoost	0.8652	0.8079	0.7810	0.8367

Conclusão

Em ambientes de desbalanceamento severo, métricas clássicas enganam. A avaliação rigorosa por **AUC-PR** expõe a real capacidade do modelo.

Modelos Ensemble de árvores superam amplamente os baselines lineares, filtrando ruídos e isolando anomalias não-lineares nos componentes PCA.

A escolha entre RF e XGBoost repousa no trade-off de negócio: custo do atrito com cliente (bloqueio indevido) vs custo direto da fraude.




Image Sources



https://miro.medium.com/v2/resize:fit:1300/1*e7uPzXUJffN8whZiUw_U6A.png

Source: pub.towardsai.net



https://miro.medium.com/v2/resize:fit:1400/1*1NtDxpcznkAr22repeu0YA.png

Source: medium.com



https://miro.medium.com/1*vhaAHJ_CmKgyrspIQUe1bA.png

Source: medium.com




Thumbnail for

machinelearningmastery.com

<https://machinelearningmastery.com/wp-content/uploads/2014/11/ROC1.png>

Source: machinelearningmastery.com



<https://machinelearningmastery.com/wp-content/uploads/2016/07/XGBoost-Feature-Importance-Bar-Chart.png>

Source: machinelearningmastery.com



<https://towardsdatascience.com/wp-content/uploads/2024/09/1qARgbCtsUIQwtk24bPecEg.png>

Source: towardsdatascience.com

Image Sources



https://cdn.prod.website-files.com/65d609edcc331dd0e4eb519b/6792ab15f89355d134b18b2a_SIEM%20graph%20visualizing%20security%20data%20for%20faster%20threat%20detection.png

Source: www.puppygraph.com